

AI 日报 · 2026-09-15

数据日期：2026-09-15 生成日期：2026-09-15

今日 AI 动态 已仅使用 LearnPrompt/ai-news-radar 公开数据，并按重要性、多源确认、新鲜度和质量规则整理本地日报。

先进模型动态

1. DeepSeek-V4.1-Flash (Max) 进入 Agent Arena 开源模型第 3 名 - X : Arena (@arena)

简要描述：DeepSeek-V4.1-Flash (Max) 进入 Agent Arena 开源模型第 3 名，净提升 +4.87%，每任务中位成本 \$0.07，重塑 Pareto 前沿...。重点涉及：Max、Agent Arena、Pareto、Confirmed Success；关键数据包括：V4.1、4.87、0.07。

<https://x.com/arena/status/2099549108013006958>

2. 在 Copilot 自动模型选择中配置成本与质量 / Configure cost and quality in Copilot auto model selection - Official AI Updates

简要描述：GitHub Copilot auto model selection now offers three tiers: efficiency, balance, and intelligence. Choose the tier that reflects how you want auto to...。

<https://github.blog/changelog/2026-09-14-configure-cost-and-quality-in-copilot-auto-model-selection>

3. GPT-5.6 Luna 对比 GPT-6 Astra : \$1.20 的模型做代码评审够用吗 / GPT-5.6 Luna vs. GPT-6 Astra : Is a \$1.20 Model Good Enough for Code Review ? - Hacker News

简要描述：Hacker News 等来源显示，GPT-5.6 Luna 对比 GPT-6 Astra : \$1.20 的模型做代码评审够用吗。重点涉及：GPT-5.6 Luna、GPT-6 Astra、Astra、Is a；关键数据包括：5.6、1.20、1.20M。2 个来源交叉出现。

<https://entelligence.ai/blogs/gpt-5.6-luna-vs-gpt-6-astra-is-a-1.20-model-good-enough-for-code-review>

4. Perplexity 把端到端系统交给 GPT-6 Astra / Perplexity trusts GPT-6 Astra with end-to-end systems - Official AI Updates

简要描述：OpenAI News 的官方更新显示，Perplexity 把端到端系统交给 GPT-6 Astra。重点涉及：Perplexity、GPT-6 Astra、perplexity improving accuracy with astra。

<https://openai.com/index/perplexity-improving-accuracy-with-astra>

5. DeepSeek-V4.1-Flash 上线千问 AI 平台，API 与 Token Plan 同步开放 - Aibase

简要描述：据平台公告，该模型为 DeepSeek 新一代轻量旗舰，总参数 552B 的 MoE 架构，采用 Causal-Encoder-Decoder 非对称结构，输入激活约 8B、输出激活约 16B；原生支持文本与图像理解，最长上下文 100 万 token，平台最大输出约 393K。

<https://www.aibase.com/news/31028>

6. ElevenLabs 发布 Music v2.5 音频模型，同步开放 APP 与 API 访问 - Aibase

简要描述：人工智能语音生成技术初创公司 ElevenLabs 于 3 日正式推出其全新的 ElevenMusic Music v2.5 版本，并同步通过移动应用程序与 API 形式向全球开发者及用户开放。作为生成式音乐领域的最新迭代作品，Music v2.5 进一步提升了音频的饱满度与自然感。在一项基于 47,885 对样本的盲...。

<https://www.aibase.com/news/31030>

7. GPT-6 Astra 展现恐怖统治力：模拟售货机一年狂揽 1.5 万美元，成绩碾压 Claude 近 3 倍 - Aibase

简要描述：相比之下，Claude Fable 5.1 的采购成本持续上涨，并因未能严格坚持规则而导致了大量预付款损失。

<https://www.aibase.com/news/31035>

8. Suno发布v6音乐模型：联合华纳、BMG 共创，自然语言就能改歌、混音、采样 - AIbase

简要描述：用自然语言就能改歌曲的某一段，而留下你已喜欢的其他部分，比如"把合唱改成福音唱诗班来唱"；一次请求里就能从多首歌拼混音，拉来 x 的人声、y 的鼓点，再加新歌词做成80年代合成器浪潮；在一条工作流里采样、隔离并围绕某个乐句建节拍；从氛围、流派或灵感混搭起手，让模型抓"屋顶午夜"那种感觉当原创起点。

...

<https://www.aibase.com/news/31033>

9. 百图生科牵手华大智造：联合构建专属细胞大模型，押注"设备+模型+智能体"一体化 - AIbase

简要描述：据 AIbase，百图生科牵手华大智造：联合构建专属细胞大模型，押注"设备+模型+智能体"一体化。
重点涉及：设备+模型+智能体。

<https://www.aibase.com/news/31027>

10. 蓝虫具身发布模块化人形机器人“小白”，0.98 万元起售 - AIbase

简要描述：具体参数方面，“小白”整机高度为1.4米，具备22个全身自由度，单臂负载能力达到7kg，臂展为663mm，遥控延迟低于10ms。

<https://www.aibase.com/news/31038>

11. Anthropic 牵手 Rum Group 签下 137 亿美元算力大单，背后是特朗普关联的社交老玩家 - AIbase

简要描述：据知情人士透露，这家 Claude 开发商与 Rum Group 签下一份为期六年、价值 137 亿美元的算力采购协议。

<https://www.aibase.com/news/31019>

12. OpenAI 推出 Agents API：把 Codex 拆成云端服务，"造 Agent" 变成一次 API 调用 - AIbase

简要描述：OpenAI 近日一口气放出四项产品更新，覆盖 Agent、语音交互、数据管理和金融服务四大领域，而真正让开发者眼睛发亮的，是其中的 Agents API。它把 Codex 的能力拆解成云端服务，用“能力即服务”的模式交付，把搭建智能体的门槛一下子压了下来——这被视作 Open...

<https://www.aibase.com/news/31025>

13. vLLM-Omni 与 FastH3 助力 MiniMax H3 迈入实时服务时代 - AIbase

简要描述：测试数据显示，在八卡 B300 的硬件配置下，这套系统级优化方案将完整的响应时延相对 Diffusers 降低了 30.8%，为高性能实时服务奠定了坚实的基础。

<https://www.aibase.com/news/31010>

14. DeepSeek 传闻将推 3 万亿参数 Code 2.0，剑指 GPT-6 Astra - AIbase

简要描述：从行业格局来看，目前国内参数量领先的产品包括 K3 的 2.8 万亿、千问 Qwen3.8Max 的 2.4 万亿，以及 DeepSeek V4Pro 的 1.6 万亿。

<https://www.aibase.com/news/31014>

15. 月之暗面王牌主力模型 K2.8Preview 全量上线，性能直逼旗舰 K3 - AIbase

简要描述：据官方透露，该模型在综合性能上已经无限接近其旗舰级别的 Kimi K3 模型，尤其在编程（Coding）与智能体（Agent）能力上实现了显著提升，同时全面支持 1M（100 万）超长上下文，且面向所有会员档位开放。

<https://www.aibase.com/news/31016>

16. 微软扩展 Copilot 模型库:SpaceX AI Grok 正式上线 Word、Excel 与 PowerPoint - AIbase

简要描述：微软 9 月 12 日宣布，正式在 Microsoft 365 Copilot 中引入来自 SpaceX AI 的 Grok 模型。

<https://www.aibase.com/news/31013>

17. 爆料称 DeepSeek 下一波大模型将至：3 万亿参数，性能剑指 GPT-6 Astra - Albase

简要描述：本周 DeepSeek 发布了 V4.1 Flash，这个大模型架构变化之大，完全可以称得上是 V5，但 DeepSeek 很低调地没有更换大版本号。Pro 系列的新品已确定为 V4.1 Pro，具体升级尚未公布；如果是 V4 到 V4.1 这样的提升幅度，V4.1 Pro 的性能上限也会很高，但...

<https://www.aibase.com/news/31026>

算力中心与基础设施

18. OpenAI 关停史上最快模型 GPT-5.3-Codex-Spark：从发布到下线只活了 7 个月 - Albase

简要描述：这款每秒 1200 个 Token、OpenAI 第一个逃离英伟达的模型、750 兆瓦 Cerebras 大单的第一份交付，从发布到下线只活了 7 个月。

<https://www.aibase.com/news/31021>

19. 智谱获50亿美元新融资 全面加速下一代GLM递归自我改进 - Albase

简要描述：9月13日晚间，人工智能企业智谱宣布完成约50亿美元的大额融资。本轮融资资金将重点用于下一代 GLM 基础模型研发、完全自训练体系打造以及相关算力基础设施建设。在具体的研发路线规划中，智谱将“完全自训练”明确为下一代 GLM 模型突破的核心要义，即让下一代 GLM 在上一代 GLM 所构建的智能环境中进行训练，以...

<https://www.aibase.com/news/31009>

技术突破、论文评测与全球头条

20. 科技巨头放缓 AI 开发的口头协议是安全共识还是卡特尔 / Is Big Tech's AI slowdown a safety pact or a cartel? - The Verge

简要描述：The Verge 等来源显示，科技巨头放缓 AI 开发的口头协议是安全共识还是卡特尔。重点涉及：Is Big Tech、AI slowdown a safety、is big techs ai slowdown a safety pact or a cartel。2 个来源交叉出现。

<https://www.theverge.com/ai-artificial-intelligence/995186/is-big-techs-ai-slowdown-a-safety-pact-or-a-cartel>

21. YC 总裁反对封杀蒸馏：与其禁，不如让开源实验室走“正门”合法获取能力 - Albase

简要描述：9 月，Anthropic 发布了第二份威胁情报报告，指控中国实验室搞“非法蒸馏攻击”——隐藏身份、靠欺诈和盗取的凭证来套取前沿模型的能力。

<https://www.aibase.com/news/31037>

22. 京东在 JDD 上甩出可交互视听世界模型：EchoWM 开源，长视频生成同步冲到 10 分钟以上 - Albase

简要描述：9月9日的京东全球科技探索者大会（JDD）上，京东探索研究院端出了 JoyAI-Echo 系列的两项新进展：超长音视频生成模型升到 JoyAI-Echo1.5，同时发布并开源可交互视听世界模型 EchoWM。

<https://www.aibase.com/news/31024>

23. 全新 Apple TV 或今秋低调发布：换上更强芯片，Siri 成核心升级 - Albase

简要描述：这是自 2022 年搭载 A15 仿生芯片的 Apple TV 4K 发布以来的首次重大换代，核心突破在于底层算力的代际跃迁。

<https://www.aibase.com/news/31011>

24. 智能体跑长任务为何“失忆跑题”：AWS、Claude Code、Manus 们用四套框架机制给出答案 - Albase

简要描述：但苏黎世联邦理工的研究泼了冷水：AGENTS.md 这类上下文文件通常不提升成功率，却让推理成本涨 20% 到 23%，每次重载都是对注意力预算的固定征税。

<https://www.aibase.com/news/31020>

25. 月费10美元!开源AI编码工具 OpenCode Go 宣布实现收支平衡 - AIbase

简要描述：人工智能编码工具 OpenCode 联合创始人 Dax Raad 于2026年9月12日宣布，旗下每月仅需10美元的低成本订阅服务 OpenCode Go 已连续两周实现收支平衡。在当前多数 AI 编码工具仍面临高额烧钱或通过数据出售方案变现的行业背景下，这一进展标志着低价 AI 订阅模式在商业可...

<https://www.aibase.com/news/31022>

26. 谷歌 DeepMind 安全研究员离职：AI 五年内造成巨大危害的概率“高得吓人” - AIbase

简要描述：他警告，递归自我提升（RSI）——即 AI 系统辅助迭代出能力更强的下一代 AI 模型——如果对齐技术跟不上模型能力的增长，就会产生危险。

<https://www.aibase.com/news/31012>

其他重要 AI 产业新闻

27. 恶意 AI 智能体攻击 RubyGems.org：YARD 执行任意代码与 Fastly 缓存密钥利用分析 / What a time to be alive - rouge AI agents attack RubyGems.org - tenderlovmaking.com

简要描述：Hacker News 等来源显示，恶意 AI 智能体攻击 RubyGems.org：YARD 执行任意代码与 Fastly 缓存密钥利用分析。重点涉及：RubyGems.org、YARD、Fastly、What a time to。4 个来源交叉出现。

<https://tenderlovmaking.com/2026/09/11/what-a-time-to-be-alive>

28. WorkBuddy 升级 PPT 能力:一句话生成可上台版，原文件可续改 - AIbase

简要描述：腾讯 WorkBuddy 于9月14日宣布升级 PPT 生成能力，主打“一句话出初稿、原文件续改、不重做整份”。

<https://www.aibase.com/news/31036>

29. 宇树人形机器人G1+发布:电机、视觉、交互与续航全面增强 标准版售价9.5万元 - AIbase

简要描述：整机电机系统同步升级，肩、腰部电机峰值扭矩提升110%，同扭矩发热下降72%;手臂电机峰值扭矩提升43%、发热下降30%，大腿电机同扭矩发热下降28%。

<https://www.aibase.com/news/31032>

30. 英国试点 AI 训练营：用 AI 破解青年失业，70 名尼特族青年先学起来 - AIbase

简要描述：他认为检验训练营及后续学徒项目成效的关键，在于 AI 培训的质量以及新入职人员能否切实提升雇主的生产效率。

<https://www.aibase.com/news/31015>